

清华大学本科生毕业设计

开题报告

题 目： 基于频域混合专家架构的流匹配策略网络

院 系： 自动化系

学 科： 自动化

学 号： 2022010153

姓 名： 张博仕

指导教师： 张涛 教授

2025 年 12 月

目录

1 选题背景	2
2 文献综述	2
2.1 传统策略学习的局限性	2
2.2 基于生成建模的策略学习新范式：扩散模型与流匹配	3
2.3 混合专家（MoE）策略在多技能学习中的应用	4
2.4 动作频域分析与分频建模的新探索	6
2.5 综合分析	7
3 研究方法	8
3.1 整体技术方案	8
3.2 数学形式化与理论基础	10
3.2.1 混合专家（MoE）的门控与路由	10
3.2.2 频域专家的输出与融合	11
3.2.3 流匹配（Flow Matching）生成框架	12
3.2.4 一致性约束（Consistency Constraint）	13
3.2.5 综合训练目标	13
3.3 实现细节与优化策略	15
4 研究目标与内容	16
5 创新点	17
6 实验方案	18
7 进度安排	20

1 选题背景

近年来，视觉机器人策略学习引入了扩散与流匹配模型，能在高维连续动作空间建模多峰分布并提升性能。扩散策略多步采样质量高但延迟大；Consistency Flow Matching 可一步生成高质量动作、显著加速。Flow Matching (Lipman 等人 [2]) 通过学习连续时间向量场，将先验分布映射到数据分布；FreqPolicy[13] 在此基础上加入频域一致性约束，强化跨时刻的相干性，实现效率与平滑性的兼顾。但在长时执行中仍可观察到高频抖动累积，影响末端轨迹稳定。

为缓解高频抖动且保留快速响应，本研究提出在 FlowMatching 的基础上引入**混合专家架构 (MoE)** 的频域分工：按频段由不同专家生成低频趋势与高频细节，并由门控网络自适应融合。低频专家负责平滑大尺度动作，高频专家专注细节调整，减少相互干扰。门控网络基于当前状态动态分配专家权重，实现频段间的协同与平滑过渡。此设计借鉴了 VFP[6] 中 MoE 在多任务中的成功应用，同时结合 FreqPolicy 的高效流匹配生成。

本研究目标是以小参数增量实现分频段建模，抑制高频噪声导致的抖动，同时保持一步生成的实时性与精度，提升任务成功率与轨迹平滑度。

2 文献综述

2.1 传统策略学习的局限性

机器人策略学习传统上包括强化学习和模仿学习两大范式。然而，这些传统方法在应对多任务、多模态需求时存在明显局限。一方面，单一策略模型难以同时胜任多种任务，常出现任务干扰现象：在多任务场景下，不同技能之间的冲突会导致策略输出趋于平均，难以专注于各任务的最佳行为。这种“平均效应”已在实践中被观察到 [9]。例如，在多任务机器人操作中，单一策略网络往往对不同任务的演示进行平均，从而无法重现各任务独特的操作策略，整体性能相较单任务情形显著下降 [9]。

另一方面，策略多模态性也是一大挑战：复杂操作任务往往存在不止一种成功执行方式，但传统策略模型（例如高斯策略或简单的行为克隆网络）缺乏表达多峰分布的能力，容易对不同演示策略取均值，导致生成的动作序列并不对应任何真实演示轨迹。这种“多模态平均”问题在机器人避障等任务中尤为明显：当演示中存在绕不同方向避障的多种路径时，传统方法可能学得折中的路径，反而造成碰撞失败 [6, 7]。

此外，实时高效决策也是传统策略学习的弱项。强化学习在训练阶段需要大量在线

试错采样，训练成本高且在真实机器人上存在安全风险；而行为克隆虽推理快速，但在高维视觉输入下训练得到的策略网络推理延迟仍可能较高。一些近年来兴起的方法试图通过生成模型提升决策质量，例如扩散模型引入了随机性来刻画多模态，但典型扩散模型需要反复逐步迭代去噪采样，一次决策往往耗费数十步计算 [1]。这种多步推理既降低了运行速度，又可能在每步引入微小误差并在时间上累积成高频抖动，削弱控制稳定性。

总的来说，传统策略学习在多任务干扰、多模态表达和实时高效性方面的不足，促使研究者探索新的策略生成框架与结构化模型，以提升机器人操作的稳定性与效率。

2.2 基于生成建模的策略学习新范式：扩散模型与流匹配

针对传统方法的上述局限，近年来出现了将生成式建模引入策略学习的新范式。其中，扩散模型（Diffusion Policy）在机器人视觉操作中取得了突破：通过将机器人策略表示为条件去噪扩散过程，能够直接从专家演示中学习复杂的动作分布 [1]。例如，Chi 等人（2023）提出的 Diffusion Policy 模型在复杂灵巧操作任务上实现了自主策略学习，其多步去噪生成过程可以捕获演示的多样性 [1]。

然而，扩散策略的缺点也很明显：推理开销大、速度慢。每次动作采样需要经过数十次迭代步才能将噪声分布变换为策略输出，这对于要求实时性的机器人控制来说代价过高 [1]。为了解决这一问题，研究者提出了流匹配（Flow Matching）策略学习框架，它以连续时间概率流的形式来生成动作，不需要严格的可逆性约束，也无需多次迭代采样 [2]。Lipman 等人（2023）首先提出了流匹配生成模型的原理 [2]：直接学习一个将简单初始分布连续映射到目标分布的速度场，训练时通过最小化生成轨迹与数据分布轨迹的差异来匹配流 [2]。这一方法在不损失生成灵活性的情况下显著减少了推理步骤，被迅速引入机器人策略学习领域 [3]。

基于流匹配思想，许多变体模型相继涌现，旨在实现单步高速策略生成。Rectified Flow 是其中的代表工作之一：Liu 等人提出通过学习“近似直线”的流，将扩散多步生成近似为单步校正 [4]。Xue 等人（2025）进一步将其应用于视觉模仿学习，提出 RecFlow Policy，用校正后的确定性流替代扩散过程 [5]。该方法在推理速度和策略精度上都较扩散策略有大幅提升，实现了仅一步从随机噪声生成高质量动作 [5]。实验表明，RecFlow 在多种模拟和真实任务上性能可与扩散策略相当或更优，但推理延迟大幅降低，具备实时部署潜力 [5]。

与此类似，Zhang 等人（2024）提出了 FlowPolicy 框架，使用一致性流匹配（Consistency Flow Matching）的思想来提升生成效率 [3]。该方法通过约束速度场的一致性

来学习近似直线的流迁移，使不同时间尺度的流都指向同一动作空间 [3]。借助这一训练策略，FlowPolicy 能够在单步推理中从视觉输入直接产生机器人动作，相比扩散策略推理速度提高了约七倍，而任务成功率与最先进方法相当 [3]。这一结果证明了一致性流匹配用于机器人决策的价值：无需多步逐渐逼近，仅一次前向计算即可完成从噪声到动作的映射 [3]。

除了提速，流匹配范式还带来了更平滑、更稳健的控制表现。Braun 等人 (2024) 提出的 Riemannian Flow Matching Policy (RFMP) 将流匹配扩展到黎曼流形上的机器人状态空间，体现出对几何约束的天然适应 [7]。他们的研究表明，RFMP 在状态为关节角、四元数等非欧几里得空间时，仍能高效训练和推理，并且与扩散策略相比，RFMP 生成的动作轨迹更加平滑，推理延迟明显降低 [7]。这意味着流匹配策略在减少高频抖动方面具有先天优势：由于不依赖多步随机采样，动作输出的连贯性和确定性更好，从而提高了实时控制的稳定性 [7]。

综上，Flow Matching 及其改进方法（如 Rectified Flow[4]、Consistency Flow Matching[3] 等）为机器人策略学习提供了一条新路径：通过生成式模型学习专家演示分布，在保持多模态表达能力的同时，实现高效单步推理和平稳控制 [3, 7]。这一框架正在迅速发展，并与其它技术结合来克服传统策略学习的瓶颈。

2.3 混合专家 (MoE) 策略在多技能学习中的应用

为了解决多任务、多技能学习中的干扰和适应性问题，另一条重要的发展方向是引入混合专家 (Mixture-of-Experts, MoE) 架构。MoE 通过设置多个专家网络，每个专家负责不同的子任务或数据子空间，由一个门控机制动态选择专家组合输出，从而实现策略的模块化和“分而治之”。近期在机器人模仿学习中，MoE 方法展现出缓解任务冲突、提升多技能学习效果的显著优势。

Di-BM 框架 (Diverse skills for Behavior Models) 将 Mixture-of-Experts 引入行为克隆模型，以应对多任务演示学习 [9]。Di-BM 的核心思想是将观测空间划分给不同专家：每个专家针对特定观测分布训练，从而在状态空间的不同子区域各自擅长相应技能 [9]。通过这种专家专精，Di-BM 有效地避免了单一策略在多任务时的平均冲突；实验表明，在多个实际机械臂操作任务上，Di-BM 显著优于以往单策略基线 [9]。尤其值得关注的是，Di-BM 预训练的专家知识可以被重用：在少量新任务演示上微调时，已有专家能够快速适应新任务，实现较高的数据效率 [9]。这表明 MoE 框架下学到的技能具备模块化复用能力，减轻了以往多任务学习中新任务对旧任务的遗忘和干扰问题。

在机器人视觉语言动作 (Vision-Language-Action, VLA) 这一新兴领域，MoE 思想

也被用于大模型的层级选择与稀疏化。MoLe-VLA (Mixture-of-Layers VLA) 架构将大型多模态模型的各层视作“专家”，通过动态层跳跃来提高推理效率 [10]。该架构设计了空间-时间感知路由器 (STAR)，根据机器人当前状态选择性激活部分 Transformer 层，模拟大脑在不同认知任务中选择不同神经路径的机制 [10]。MoLe-VLA 通过这种混合层方式，大幅削减了不必要的计算，并辅以认知自蒸馏补偿因剪枝导致的语义信息损失 [10]。在 RL Bench 基准和真实机器人实验中，MoLe-VLA 在保持或提升策略成功率的同时，将大型语言模型的计算开销降低了最多 5.6 倍，平均任务成功率提升约 8% [10]。这证明了通过 MoE 式的稀疏激活，大型 VLA 模型也能兼顾性能与效率 [10]。

与之相关联的还有提交至 ICLR 2026 的一项工作 HiMoE-VLA (Hierarchical MoE VLA)，该框架关注于异构机器人数据的整合学习 [11]。该工作指出，不同机器人平台在形态、动作空间、传感器配置和控制频率等方面存在高度异质性，单一模型难以一并学习 [11]。HiMoE-VLA 因此在动作策略模块中引入层级式混合专家架构，不同层级的专家适应不同来源的异质性，并逐层提取抽象的共享表示 [11]。通过这种分层专家处理，HiMoE-VLA 在模拟和多种真实机器人平台上都取得了优于现有 VLA 方法的性能，在跨机器人、跨动作空间的迁移中表现出更强的泛化性和鲁棒性 [11]。

总的来看，MoE 策略在机器人多技能学习中具有三大突出优势：其一，减轻任务干扰，每个专家专注于特定子任务或行为模式，降低了不同技能之间参数更新的冲突 [9, 11]；其二，提高表示能力，通过混合多种专家的输出，可以表示更复杂的策略分布，包括多模态决策边界 [6]；其三，实现模块化和可扩展性，新增任务可通过增加或调整专家来适应，已有专家知识可复用以加速新任务学习 [9]。

特别是在多模态决策场景下，将 MoE 与生成式模型结合能进一步发挥优势：Zhai 等人 (2025) 的 VFP 框架正是一个例证 [6]。他们在流匹配策略中引入了变分隐变量和 MoE 解码器，用隐变量区分演示中的不同行为模式，再由多个流匹配专家分别解码各模式的动作 [6]。这种设计成功避免了标准流匹配对多模态数据“取平均”的缺陷，使策略能够覆盖演示的多样行为，同时保持流匹配模型快速推理的优势 [6]。VFP 的实验显示，在 Franka 厨房多任务环境中，传统 FlowPolicy 因无法区分模式而表现出不稳定、举棋不定的动作选择，而引入 MoE 后的 VFP 能够清晰地区分各任务模式，执行相应策略，成功率显著提高 [6]。这进一步证明，混合专家与生成模型的结合是机器人策略学习的一个强大方向，兼具了多技能表达和高效推理的优点。

2.4 动作频域分析与分频建模的新探索

除了以上从模型架构和生成机制上的改进，近期研究还关注于从动作序列的频率特性提升策略学习的稳定性与精度。机器人操作的动作序列本质上是一系列随时间演进的控制信号，包含不同频率成分：低频分量对应整体运动趋势或粗略路径，高频分量则反映细节调整或快速振荡 [12]。传统时域模型往往难以区分处理这些不同层次的信息，可能对高频部分拟合不佳或在低频趋势与高频噪声之间权衡不当。

基于这一认识，Zhong 等人（2025）提出了 FreqPolicy，引入频域分解来建模机器人视觉操作策略 [12]。他们首先使用离散余弦变换（DCT）将动作轨迹变换到频域表示，然后按频率从低到高层次化地逐步生成动作信号 [12]。具体而言，FreqPolicy 采用分阶段的自回归框架：先生成主要的低频动作粗略轮廓，再逐级细化更高频的动作细节，最终重构出完整的动作序列 [12]。同时，为确保各频段衔接平滑，作者引入连续潜变量来在频段之间传递信息，保证生成的动作在频域和时域上都保持平滑连续 [12]。这种频域上的逐级精细建模，使模型能针对不同复杂度的任务分配不同的建模精度：对于结构简单的任务，主要依赖低频分量；对于精细操作，则通过高频分量捕捉细节 [12]。实验结果表明，频域分解策略在 2D 和 3D 操作基准上均显著优于传统时域方法，在准确性和效率上取得双提升 [12]，凸显了频域层次化框架在泛化机器人操作上的潜力。

另一项相关研究由 Su 等人（2025）提出，同样命名为 FreqPolicy 但侧重于频率一致性加速 [13]。他们关注于流匹配策略的时间一致性问题：虽然流匹配能够单步生成动作，但在模型训练时需要确保不同时间步流的结果一致地收敛到专家演示分布。为此，作者提出在流匹配训练中加入频域一致性约束，鼓励流在各时间阶段产生的动作频谱特征保持对齐 [13]。这种约束有效促进了经过任意短时间流动后生成的一步动作就接近目标分布，从而实现高质量的一步生成 [13]。同时，针对机器人操作中固有的结构化时变特性，设计了自适应一致性损失来匹配不同阶段的频谱变化 [13]。

通过上述改进，该方法在多达 53 个模拟任务上全面超越已有的一步生成策略，并成功集成到大型 VLA 模型中，在 Libero 基准的 40 个任务上实现了推理加速且性能无损 [13]。更为亮眼的是，其在真实机器人上的测试达到 93.5 Hz 的决策频率，证明了在实际控制回路中运行的可行性 [13]。频域一致性的方法本质上提高了动作序列跨时间步的平滑程度，减小了由逐步生成可能引入的不连续抖动，因此提升了实时控制的稳定性 [13, 7]。

频域分析的引入，为机器人策略建模提供了一个全新视角：通过显式分离和约束不同频率的动作成分，可以平衡全局与局部运动信息，既保证整体轨迹的正确性，又兼顾细节调整的精确性。同时，频域方法有助于缓解控制中的高频振荡问题——这是许多端

到端策略网络在真实机器人上面临的挑战。如果模型未能正确处理感知噪声或延迟，容易产生高频来回纠错的抖动动作。而频域一致性约束等方法鼓励策略输出在高频范围内保持平稳，从而减少不必要的振荡 [13]。已有工作如 HiMoE-VLA 也注意到控制频率差异对策略泛化的影响，将其视作异质性因素之一来处理 [11]。不过需要指出的是，这里的控制频率指不同系统的决策周期快慢，而频域建模关注的是同一序列内部的频率成分分解，两者有所区别。

总体而言，频域方法为提升机器人连续控制的平滑性和可靠性提供了有力工具，特别是在需要高速、高精度操作的场景下，频域建模有望显著降低策略输出的抖动，提升控制质量。

2.5 综合分析

综上所述，近年来机器人策略学习领域围绕模型结构和训练范式展开了多方面的创新探索：Flow Matching 等生成式模型解决了传统策略难以表达多模态且推理缓慢的问题，实现了高效单步的策略生成 [3, 7]；Mixture-of-Experts 架构通过划分专家专攻不同子任务或行为模式，在多任务多技能学习中缓解了干扰、提升了模块化和可扩展性 [9, 11, 6]；频域分解与一致性方法关注动作序列本身的时频特性，增强了策略的平滑性与精细控制能力 [12, 13]。这些研究进展各自针对机器人决策中的瓶颈提出了解决方案，并在不同维度上取得了显著效果。

然而，现有工作大多侧重于上述某一方面的改进，尚未有研究将“MoE + Flow Matching + 频段建模”三者有机结合。例如，VFP 虽然将 MoE 引入了流匹配策略，但其专家划分基于行为模式而非频段 [6]；FreqPolicy 系列工作探索了频域上的策略生成，却未考虑利用混合专家来分别建模不同频段的动作信号 [12, 13]；而诸如 HiMoE-VLA 涉及了控制频率的异质性处理，但并未采用生成式的流匹配框架或频域一致性约束来优化实时控制的平滑度 [11]。

因此，本研究融合 MoE 的模块化优势、Flow Matching 的高效生成以及频段划分的平滑控制能力，来应对高频抖动并提升实时控制稳定性与效率。设想一种基于频段划分的混合专家策略网络：利用频域滤波将机器人动作分解为不同频率带的成分，由不同专家分别预测各频段的控制信号，高频专家侧重细节和快速响应，低频专家负责全局运动趋势。然后，通过 Flow Matching 框架对整体策略进行一致性约束和高效训练，在单步推理中融合各专家输出，重构最终动作。这样的架构有望将各领域进展的优势叠加：MoE 专家各司其职，避免不同频段信号相互干扰；流匹配保证生成过程的简洁高效；频段划分确保高频部分受到专门约束，从而抑制不必要的快速振荡。

本研究在充分调研上述文献的基础上，将构建上述创新框架，以期显著缓解机器人操作策略中的高频抖动问题，在实现实时、高精度控制方面取得新的突破，有望形成一种通用范式，为多任务、多尺度机器人控制策略的设计提供崭新的思路和工具。

3 研究方法

3.1 整体技术方案

本课题提出的频域混合专家策略网络（Freq-MoE-Policy）的技术方案如图 1 所示。整体架构可分为以下几个关键模块：

视觉编码与流匹配主干 采用与 FreqPolicy 相同的视觉模态输入处理：利用机器人的多视角 RGB-D 图像或点云作为观测输入 $\mathbf{o}_t$ ，通过卷积神经网络或点云编码器提取环境的几何与语义特征，得到状态表示 $\mathbf{s}_t$ 。该状态表示输入基于 Consistency Flow Matching 的连续流模型，通过学习概率流 ODE，从先验分布（如高斯噪声）一步映射到动作分布，生成隐含动作编码 $h \in \mathbb{R}^d$ 。该隐含编码包含了时域动作序列的全部信息，但尚未显式区分不同频率成分。

频域混合专家模块 这是本研究的核心创新。本研究在输出层引入频域专家分解机制：

1. **频域表示**：定义动作序列的频域表示 $\mathbf{A} \in \mathbb{R}^{T \times d_a}$ （其中 T 为序列长度， d_a 为动作维度），它是时域动作序列 $\mathbf{a}$ 经离散余弦变换（DCT）得到：

$$\mathbf{A} = \text{DCT}(\mathbf{a}) \in \mathbb{R}^{T \times d_a}. \quad (1)$$

频谱 $\mathbf{A}$ 的不同频率索引对应动作序列的不同时间尺度特征：低频分量刻画整体运动趋势，高频分量反映细节调整。各专家将在频域空间直接操作，输出频域增量，从而实现频段解耦。

2. **频段划分与专家分配**：预先设定 K 个频段 $\{\mathcal{B}_1, \mathcal{B}_2, \dots, \mathcal{B}_K\}$ ，例如将频谱划分为低频段（对应平滑的大尺度运动）、中频段（对应常规动作切换）、高频段（对应接触瞬间的快速调整）等。每个频段 $\mathcal{B}_i$ 对应一个专家网络 E_i 。各专家为参数量较小的多层感知机（MLP）或卷积网络。

3. **专家输出**: 每个专家 E_i 以隐含动作编码 h 为输入, 输出该频段的频域增量 $\Delta \mathbf{A}_i \in \mathbb{R}^{T \times d_a}$:

$$\Delta \mathbf{A}_i = E_i(h), \quad i = 1, \dots, K. \quad (2)$$

为确保各专家输出仅作用于其指定频段, 引入带通掩码 $\mathbf{M}_i \in \{0, 1\}^{T \times d_a}$, 该掩码在频段 $\mathcal{B}_i$ 内为 1, 其它位置为 0。专家的有效输出为:

$$\tilde{\mathbf{A}}_i = \mathbf{M}_i \odot \Delta \mathbf{A}_i, \quad (3)$$

其中 $\odot$ 表示逐元素乘法。这样, $\tilde{\mathbf{A}}_i$ 仅在频段 $\mathcal{B}_i$ 的频率成分上非零, 实现了频段的物理隔离。

门控路由网络 为动态融合各专家的输出, 设计门控网络 G 来自适应地分配专家权重。门控网络的输入包括: (1) 隐含动作编码 h ; (2) 当前状态的频谱特征向量 (由 h 经 DCT 后提取统计量得到); (3) 任务阶段信息, 如机器人末端是否处于接触状态 $c \in \{0, 1\}$ 等。将这些特征拼接后输入若干层感知机, 得到未归一化的门控分数:

$$g_i = G_i(h, c), \quad i = 1, \dots, K. \quad (4)$$

通过 softmax 归一化得到各专家的权重 π_i :

$$\pi_i = \frac{\exp(g_i)}{\sum_{j=1}^K \exp(g_j)}, \quad \sum_{i=1}^K \pi_i = 1. \quad (5)$$

在实际实现中, 为提高计算效率并鼓励稀疏激活, 可采用 Top- k 路由策略: 仅选择得分最高的 k 个专家激活, 其余专家权重置零。设激活集合为 $\mathcal{S} = \text{TopK}(\{g_i\})$, 则稀疏路由权重为:

$$\pi_i^{(k)} = \begin{cases} \frac{\exp(g_i)}{\sum_{j \in \mathcal{S}} \exp(g_j)}, & i \in \mathcal{S}, \\ 0, & i \notin \mathcal{S}. \end{cases} \quad (6)$$

频域加权融合与逆变换 在频域内, 将各专家输出按门控权重加权求和, 得到最终的频谱表示:

$$\hat{\mathbf{A}} = \sum_{i \in \mathcal{S}} \pi_i^{(k)} \tilde{\mathbf{A}}_i = \sum_{i \in \mathcal{S}} \pi_i^{(k)} (\mathbf{M}_i \odot \Delta \mathbf{A}_i). \quad (7)$$

该加权融合在频域完成，保证了不同频段的分量按需组合：在接触瞬间，门控网络倾向于增大高频专家权重 π_{high} ；在平滑运动阶段，低频专家权重 π_{low} 占主导。最后，通过逆离散余弦变换（IDCT）将频域融合结果转换回时域，得到最终的控制动作序列：

$$\hat{\mathbf{a}} = \text{IDCT}(\hat{\mathbf{A}}) \in \mathbb{R}^{T \times d_a}. \quad (8)$$

该架构的优势在于：各专家在频域上分工明确，低频专家专注于产生平滑的全局轨迹，高频专家负责细节修正，彼此不会在时域上直接混叠干扰；门控机制根据任务状态自适应调节各频段的贡献，实现灵活的频段组合；整个流程仅在输出头引入少量专家分支和一次 DCT/IDCT 变换，计算开销增长可控，不影响实时性。

3.2 数学形式化与理论基础

为保证理论完备性，下面系统阐述混合专家机制、流匹配生成过程以及综合训练目标的数学推导。

3.2.1 混合专家（MoE）的门控与路由

设主干网络（视觉编码器 + 流匹配模块）生成隐含动作表征 $h \in \mathbb{R}^d$ 。定义 K 个专家网络 $\{E_i : \mathbb{R}^d \rightarrow \mathbb{R}^{T \times d_a}\}_{i=1}^K$ ，每个专家将 h 映射为一个频域增量。同时定义门控网络 $G : \mathbb{R}^d \rightarrow \mathbb{R}^K$ ，其输出 $g = (g_1, \dots, g_K)^\top$ 为未归一化的专家选择分数。

密集门控（Dense Gating） 采用 softmax 对门控分数归一化，得到各专家的权重：

$$\pi_i = \frac{\exp(g_i)}{\sum_{j=1}^K \exp(g_j)}, \quad i = 1, \dots, K. \quad (9)$$

此时所有专家均被激活，最终输出为加权平均（在一般 MoE 中）或加权和（在频域 MoE 中）。

稀疏路由（Sparse Routing with Top- k ） 为降低计算量并增强专家专业性，采用稀疏激活策略。定义 Top- k 操作：

$$\mathcal{S} = \text{TopK}(\{g_1, \dots, g_K\}, k) = \{i : g_i \text{ 在所有 } g_j \text{ 中排名前 } k\}. \quad (10)$$

仅对 $\mathcal{S}$ 中的专家进行归一化：

$$\pi_i^{(k)} = \begin{cases} \frac{\exp(g_i)}{\sum_{j \in \mathcal{S}} \exp(g_j)}, & i \in \mathcal{S}, \\ 0, & i \notin \mathcal{S}. \end{cases} \quad (11)$$

这样在前向传播时仅计算 k 个专家的输出，大幅降低推理开销。

专家负载均衡 在训练过程中，若门控网络偏好某几个专家，会导致其它专家得不到充分训练。为避免专家失衡，引入负载均衡辅助损失 [8]。对一个训练批次 $\mathcal{B} = \{h^{(n)}\}_{n=1}^N$ ，定义专家 i 的负载（被选次数）：

$$L_i = \sum_{n=1}^N \mathbb{I}[i \in \mathcal{S}^{(n)}], \quad (12)$$

以及专家 i 的期望门控质量（累积权重）：

$$M_i = \sum_{n=1}^N \pi_i^{(k,n)}. \quad (13)$$

负载均衡损失定义为：

$$\mathcal{L}_{\text{balance}} = \lambda_{\text{bal}} \cdot K \sum_{i=1}^K \left(\frac{L_i}{\sum_{j=1}^K L_j} \right) \left(\frac{M_i}{\sum_{j=1}^K M_j} \right), \quad (14)$$

其中 λ_{bal} 为平衡系数。该损失项鼓励专家的负载和质量在批次内均匀分布，防止少数专家垄断。

3.2.2 频域专家的输出与融合

在标准 MoE 中，专家直接输出最终预测；而在本研究的频域 MoE 框架中，专家在频域上操作。具体而言：

给定隐含动作表征 h 和真实时域动作 $\mathbf{a}^* \in \mathbb{R}^{T \times d_a}$ ，首先计算真实动作的频谱：

$$\mathbf{A}^* = \text{DCT}(\mathbf{a}^*). \quad (15)$$

各专家 E_i 输出频域增量:

$$\Delta \mathbf{A}_i = E_i(h), \quad i = 1, \dots, K. \quad (16)$$

为约束专家 E_i 仅作用于其指定频段 $\mathcal{B}_i$, 定义带通掩码 $\mathbf{M}_i \in \{0, 1\}^{T \times d_a}$:

$$(\mathbf{M}_i)_{t,j} = \begin{cases} 1, & \text{若频率索引 } t \in \mathcal{B}_i, \\ 0, & \text{否则.} \end{cases} \quad (17)$$

专家的有效输出为:

$$\tilde{\mathbf{A}}_i = \mathbf{M}_i \odot \Delta \mathbf{A}_i. \quad (18)$$

在频域按门控权重加权融合:

$$\hat{\mathbf{A}} = \sum_{i \in \mathcal{S}} \pi_i^{(k)} \tilde{\mathbf{A}}_i = \sum_{i \in \mathcal{S}} \pi_i^{(k)} (\mathbf{M}_i \odot \Delta \mathbf{A}_i). \quad (19)$$

逆变换回时域得到最终预测动作:

$$\hat{\mathbf{a}} = \text{IDCT}(\hat{\mathbf{A}}). \quad (20)$$

这一流程保证了各专家在频域上各司其职, 融合后的动作既包含低频的平滑趋势, 又包含高频的细节修正。

3.2.3 流匹配 (Flow Matching) 生成框架

Flow Matching[2] 是一种生成模型框架, 通过学习连续时间向量场将先验分布映射到数据分布。在策略学习中, 它用于从噪声分布一步生成高质量动作。

概率流 ODE 定义连续时间 $t \in [0, 1]$, 在该时间上学习向量场 $v_t: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 。给定初始分布 p_0 (如标准高斯 $\mathcal{N}(0, I)$) 和目标数据分布 p_1 (专家演示动作分布), 概率流 ODE 为:

$$\frac{dx_t}{dt} = v_t(x_t), \quad x_0 \sim p_0, \quad x_1 \sim p_1. \quad (21)$$

该 ODE 满足连续性方程 (Fokker-Planck 方程的确定性版本):

$$\frac{\partial p_t(x)}{\partial t} + \nabla \cdot (p_t(x) v_t(x)) = 0. \quad (22)$$

条件流匹配 在条件策略生成中，向量场依赖于观测 $\mathbf{o}$: $v_t(x|\mathbf{o})$ 。训练目标是 minimized 向量场与数据耦合路径速度之间的差异。构造耦合分布 $\gamma(x_0, x_1|\mathbf{o})$ (通常取 $x_0 \sim \mathcal{N}(0, I)$, $x_1 \sim p_{\text{data}}(\cdot|\mathbf{o})$)，定义插值路径：

$$x_t = (1 - t)x_0 + tx_1, \quad t \in [0, 1]. \quad (23)$$

目标速度（直线耦合路径的切向量）为：

$$u_t(x_0, x_1) = x_1 - x_0. \quad (24)$$

Flow Matching 损失定义为：

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t \sim \mathcal{U}(0,1)} \mathbb{E}_{(x_0, x_1) \sim \gamma} \mathbb{E}_{\mathbf{o}} \left[\left\| v_t(x_t|\mathbf{o}) - u_t(x_0, x_1) \right\|_2^2 \right]. \quad (25)$$

最小化该损失使得学到的向量场能够在任意 t 时刻将 x_t 沿正确方向推向 x_1 。当 $t = 0$ 时，一步推理即可从噪声 x_0 生成接近数据分布的样本 $\hat{x}_1 \approx x_1$ 。

3.2.4 一致性约束 (Consistency Constraint)

Consistency Flow Matching 进一步引入时域和频域的一致性约束，确保生成的动作序列在不同时刻和频率上保持平滑。设在时刻 t 生成的隐含动作为 h_t ，其频谱为：

$$H_t = \text{DCT}(h_t). \quad (26)$$

定义一致性目标 h_t^* 和 H_t^* (可由教师模型、自蒸馏或指数移动平均提供)。一致性损失为：

$$\mathcal{L}_{\text{cons}} = \mathbb{E}_t \left[\|h_t - h_t^*\|_2^2 + \lambda_f \|H_t - H_t^*\|_2^2 \right], \quad (27)$$

其中 λ_f 为频域一致性权重。该损失鼓励模型在时域和频域同时逼近目标，增强生成的平滑性和稳定性。

在频域 MoE 框架中，本研究将 $\mathcal{L}_{\text{cons}}$ 分配到各频段：对每个专家 i 负责的频段 $\mathcal{B}_i$ ，约束其输出的频谱分量与目标一致，从而强化子带的精细建模。

3.2.5 综合训练目标

综合上述各项损失，完整的训练目标包含以下五个部分：

1. 子带频域一致性损失 对每个专家 i ，要求其在频段 $\mathcal{B}_i$ 上的输出与真实动作的对应频段接近：

$$\mathcal{L}_{\text{subband}} = \sum_{i=1}^K \alpha_i \left\| \mathbf{M}_i \odot \Delta \mathbf{A}_i - \mathbf{M}_i \odot \mathbf{A}^* \right\|_2^2, \quad (28)$$

其中 α_i 为专家 i 的权重系数， $\mathbf{A}^* = \text{DCT}(\mathbf{a}^*)$ 为真实动作的频谱。

2. 整体时域精度损失 确保融合后的最终动作 $\hat{\mathbf{a}}$ 与真实动作 $\mathbf{a}^*$ 在时域上接近：

$$\mathcal{L}_{\text{whole}} = \beta \left\| \hat{\mathbf{a}} - \mathbf{a}^* \right\|_2^2, \quad (29)$$

其中 β 为整体损失权重。

3. 流匹配主损失 如公式(25)所示，确保生成模型学习正确的概率流：

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t, x_0, x_1, \mathbf{o}} \left[\left\| v_t(x_t | \mathbf{o}) - (x_1 - x_0) \right\|_2^2 \right], \quad (30)$$

其权重为 γ 。

4. 一致性损失 如公式(27)所示，约束时域和频域一致性：

$$\mathcal{L}_{\text{cons}} = \mathbb{E}_t \left[\left\| h_t - h_t^* \right\|_2^2 + \lambda_f \left\| H_t - H_t^* \right\|_2^2 \right], \quad (31)$$

其权重为 η 。

5. 路由正则项 包括负载均衡损失(14)和稀疏激活正则：

$$\mathcal{L}_{\text{routing}} = \mathcal{L}_{\text{balance}} + \rho \left\| \boldsymbol{\pi}^{(k)} \right\|_1, \quad (32)$$

其中 ρ 为稀疏正则系数， $\left\| \boldsymbol{\pi}^{(k)} \right\|_1 = \sum_{i=1}^K |\pi_i^{(k)}|$ 鼓励门控权重稀疏，稳定 Top- k 选择。

总损失 综合以上各项，最终的训练目标为：

$$\begin{aligned}
\min_{\theta} \mathcal{L}_{\text{total}} &= \mathcal{L}_{\text{subband}} + \mathcal{L}_{\text{whole}} + \gamma \mathcal{L}_{\text{FM}} + \eta \mathcal{L}_{\text{cons}} + \mathcal{L}_{\text{routing}} \\
&= \underbrace{\sum_{i=1}^K \alpha_i \|\mathbf{M}_i \odot \Delta \mathbf{A}_i - \mathbf{M}_i \odot \mathbf{A}^*\|_2^2}_{\text{子带频域一致性}} \\
&\quad + \underbrace{\beta \|\hat{\mathbf{a}} - \mathbf{a}^*\|_2^2}_{\text{整体时域精度}} \\
&\quad + \underbrace{\gamma \mathbb{E}_{t, x_0, x_1, \mathbf{o}} [\|v_t(x_t | \mathbf{o}) - (x_1 - x_0)\|_2^2]}_{\text{流匹配主损失}} \\
&\quad + \underbrace{\eta \mathbb{E}_t [\|h_t - h_t^*\|_2^2 + \lambda_f \|H_t - H_t^*\|_2^2]}_{\text{一致性约束}} \\
&\quad + \underbrace{\mathcal{L}_{\text{balance}} + \rho \|\boldsymbol{\pi}^{(k)}\|_1}_{\text{路由正则}},
\end{aligned} \tag{33}$$

其中 θ 表示模型的全部可训练参数（包括主干网络、各专家网络、门控网络）。超参数 $\{\alpha_i, \beta, \gamma, \eta, \lambda_f, \lambda_{\text{bal}}, \rho\}$ 通过验证集调优确定。

3.3 实现细节与优化策略

频段掩码设计 带通掩码 $\mathbf{M}_i$ 可采用两种方式：（1）固定阈值划分，例如按 DCT 系数索引 t 将 $[0, T)$ 分为 $[0, T/3[$ 低频、 $[T/3, 2T/3[$ 中频、 $[2T/3, T[$ 高频；（2）可学习掩码，将 $\mathbf{M}_i$ 参数化为 sigmoid 函数，允许网络自适应调整频段边界。实验中通常先采用固定划分验证有效性，后尝试可学习方案以进一步优化。

Top- k 路由的可微实现 由于 TopK 操作不可微，直接用于反向传播会导致梯度消失。实践中采用 Gumbel-Softmax 技巧或 Straight-Through Estimator (STE) 近似梯度，使 Top- k 在前向时稀疏激活，反向时梯度可通过 softmax 近似传播。

一致性目标的获取 h_t^* 和 H_t^* 可通过以下方式获得：（1）教师模型：先训练一个较大的模型作为教师，再用其输出作为目标；（2）自一致性：在同一批次中对同一样本多次采样，取均值作为目标；（3）指数移动平均 (EMA)：维护模型参数的 EMA 版本，用其输出作为一致性目标。实验中通常采用 EMA 策略，兼顾训练稳定性和计算效率。

联合优化策略 由于损失函数包含多个项，不同项的数值尺度可能差异较大。训练时采用以下策略：（1）预热阶段先仅优化 $\mathcal{L}_{\text{whole}}$ 和 $\mathcal{L}_{\text{FM}}$ ，使主干和专家基本收敛；（2）中期引入 $\mathcal{L}_{\text{subband}}$ 和 $\mathcal{L}_{\text{cons}}$ ，增强频段分工；（3）后期加入 $\mathcal{L}_{\text{routing}}$ 微调门控网络，平衡专家负载。各阶段权重系数逐步调整，确保训练稳定。

计算复杂度分析 相比原始 FreqPolicy，Freq-MoE-Policy 增加的计算量主要来自：（1） K 个专家前向计算，若采用 Top- k 稀疏激活且 $k \ll K$ ，实际增量为 k 个小型 MLP；（2）一次 DCT 和 IDCT 变换，复杂度为 $O(T \log T)$ ；（3）门控网络，参数量很小。理论上，总体参数量增长预计在 10%-20%，推理延迟增加预计不超过 5%，从而有望满足实时控制要求（如 50Hz-100Hz 的决策频率）。

4 研究目标与内容

本研究旨在设计一种频域混合专家策略网络（Freq-MoE-Policy），融合频域分析与多专家机制，实现对机器人操作中不同频率成分的分模块建模与控制，从而缓解高频抖动、提升策略稳定性和任务成功率。具体目标包括：

1. **频段专家模型设计**：基于离散余弦变换（DCT）将机器人动作序列分解为不同频率子带，设计对应的专家网络分别擅长于高频细节动作（如接触瞬间的迅速调整）和低频大尺度动作（如平稳移动和路径规划），使各专家在其频段上发挥专长；
2. **专家路由机制**：设计基于频谱特征和任务阶段的门控网络（gating），动态评估当前策略执行所需的频段权重。通过分析最近一段时间的动作频谱及接触状态等信息，自适应地分配各频段专家的输出权重，实现专家间的协同工作与平滑过渡；
3. **模型主体架构集成**：以 FreqPolicy[13] 的视觉模态编码和流匹配策略网络为基础，改进其输出层为多专家结构。即主干网络提取观测的空间几何特征和时序信息，经流匹配生成初步动作表征，再由多个专家头分别输出各频段动作分量，最后融合为最终控制指令。训练过程中，引入频域一致性损失约束各专家输出与对应频段的真实动作分量一致，并通过总损失加权保证整条动作的精度。
4. **验证与评估**：在仿真环境中实现所提模型，对比原始 FreqPolicy 策略，验证频域 MoE 结构在抑制高频抖动、提高任务成功率方面的有效性，并分析不同专家的工作模式与频段对应关系，验证模型的可解释性。

通过上述内容的完成，本课题将为面向复杂机器人操作任务的高效鲁棒控制策略提供新思路。




图 1: 策略网络技术路线示意图: 主干从视觉观测提取状态并通过流匹配生成隐含动作表示, 各专家在频域直接输出对应频段的动作增量, 再经门控加权融合后通过 IDCT 重构最终时域动作。高频专家侧重接触瞬间的快速细节调整, 低频专家侧重路径的平滑连贯。

5 创新点

本课题的创新体现在以下几个方面:

- 1. 频域 MoE 融合的新颖架构:** 首次将 Mixture-of-Experts 机制引入频域机器人控制策略, 将动作按频率分段由不同专家分别生成, 实现了策略网络的”频率分工”, 这是对现有扩频域一致性策略的一种全新拓展。在此前工作中, MoE 主要用于多任务或多模态分配, 而本研究聚焦于同一任务内动作频谱的内部解耦, 具有独创性。
- 2. 高效且可扩展的模型设计:** 所提 Freq-MoE-Policy 仅在原策略输出头增加少量专家分支, 主干沿用已有结构, 因而整体参数量和计算量增长很小。相比于直接提高主干网络容量以拟合复杂频率动态, 引入 MoE 实现了参数高效的扩展, 推理阶段通过稀疏激活部分专家降低冗余计算, 利于在实时系统中部署。此外, 专家数量和频段划分可根据任务需求灵活调整, 具有良好的扩展性。
- 3. 更平稳鲁棒的控制效果:** 通过频域专家的协调, 本策略在保持对快速变化响应能力的同时, 有效抑制了高频噪声放大引起的抖动, 实现高速高精操作的平稳性提升。这种优异表现将在成功率和频谱能量等量化指标以及可视化结果中得到体现。
- 4. 强解释性:** 与黑箱大模型不同, 本研究的频域专家模型能够通过观察各专家的激活权重和输出频谱, 对策略的决策依据进行解释。比如, 可以明确哪个专家在何时发挥作用, 对应哪类频率特征, 这为后续改进和安全监管提供了依据。

6 实验方案

本研究将在 CALVIN 机器人操作任务仿真环境中验证所提出的 Freq-MoE-Policy 策略。CALVIN 环境包含 34 个不同的操作任务（如抓取、放置、开关等），为评估多任务泛化能力提供了良好平台。首先，本研究将采用与 FreqPolicy（Su 等人 [13]）论文一致的训练数据和流程，使用 CALVIN 提供的专家演示数据集，包含各任务的操作演示序列。然后分别训练原始 FreqPolicy 和本研究改进的 Freq-MoE-Policy 模型。为公平比较，两种模型的主干网络和训练超参数保持一致，仅输出结构有所不同。

模型训练完成后，在独立的测试任务集上评估性能。主要评估指标包括：

1. **任务成功率：**在控制频率固定为某值（例如 20Hz 或更高，以体现实时性要求）下，让机器人在环境中连续执行指令，统计在限定时间内各任务成功完成的比例。预计相较于 FreqPolicy，加入频段专家后的模型在高难度任务上成功率有所提升，特别是涉及精细接触或快速动作切换的任务。
2. **动作轨迹频谱特性：**对比两种模型输出的动作序列，通过快速傅里叶变换（FFT）或小波分析提取其频谱能量分布，观察高频能量是否降低。具体而言，可计算动作加速度或速度信号在高频段（例如高于某阈值频率）的能量占比。预计 Freq-MoE-Policy 由于高频专家的针对性处理和门控平滑，能有效减少高频噪声能量，从定量上体现出更平滑的控制效果。
3. **专家激活模式可视化：**记录 Freq-MoE-Policy 在任务执行过程中每个时间步各专家的门控权重，绘制“专家激活热力图”（time-step vs. expert weight）。将该图与机器人动作的频谱随时间变化图进行对比，对应分析专家权重与频段特征的关系。例如，在发生接触的时刻，高频专家的权重是否显著升高，对应频谱中高频成分增加；在平稳运动阶段，低频专家是否占主导。通过此可视化，本研究将验证模型的解释性，即不同专家确实学会了在其擅长的频率范围发挥作用。

消融实验与设置

为系统评估各组件贡献，设计如下消融：

- a 专家数量与子带划分： $K \in \{1, 2, 3\}$ ；两段（低/高）与三段（低/中/高）阈值对比；可学习带通掩码 vs 固定掩码。

- b 门控路由策略：密集 softmax vs Top- k ($k = 1, 2$)；是否加入负载均衡 $\mathcal{L}_{\text{balance}}$ 与熵正则；是否使用接触状态特征。
- c 频域与一致性：DCT vs FFT；是否启用频域一致性 $\mathcal{L}_{\text{cons}}$ ；一致性权重 $\eta \in \{0, 0.1, 0.5, 1.0\}$ 。
- d 流匹配目标：是否加入 FM 主损失 $\mathcal{L}_{\text{FM}}$ ；耦合速度 u_t 线性 vs 二次时间调度； $\gamma \in \{0, 0.1, 0.5, 1.0\}$ 。
- e 子带权重与整体损失： α_i 的均匀/递减（随频率）设定；整体权重 $\beta \in \{0.5, 1.0\}$ ；路由稀疏项 $\rho \in \{0, 10^{-4}, 10^{-3}\}$ 。
- f 稳健性：添加高斯观测噪声与动作扰动；随机接触抖动注入；对比鲁棒性指标（成功率跌幅、恢复时间）。

每组实验在相同训练预算和随机种子下重复 3 次，报告均值与标准差，并进行配对 t 检验 ($p < 0.05$)。

消融设置一览

Configuration	Values	Expected Impact	Metrics
K	1/2/3	Vibration suppression vs. accuracy	Success rate, HF energy
Subband division	2/3-band, fixed/learnable	Fine-grained control	Smoothness, latency
Gating	Dense/Top- k ($k = 1, 2$)	Load balancing, sparsity	Throughput, entropy
η	0/0.1/0.5/1.0	Smoothness, consistency	HF energy, SNR
γ	0/0.1/0.5/1.0	One-step quality	Trajectory error
α_i	Uniform/decay	HF suppression	HF ratio, jitter
ρ	0/10 ⁻⁴ /10 ⁻³	Computation vs. generalization	Inference Hz
Transform	DCT/FFT	Subband separability	Consistency error
Perturbation	Noise/jitter injection	Robustness	Drop %, recovery time

表 1: Ablation configurations. See Notation for symbol definitions. HF: high-frequency.

除上述主要评估外，本研究还计划测试不同专家数量和频段划分对性能的影响（例如 2 个专家 vs 3 个专家；频段阈值选择等），以及在存在外部扰动（sensor noise）时模型的鲁棒性。所有实验均多次重复以获取平均值并进行统计显著性检验。

7 进度安排

本研究计划自开题通过后，按照以下时间进度展开：

- **2025 年 12 月–2026 年 1 月：**深入阅读相关文献，完善开题报告。重点研读频域策略（FreqPolicy）和混合专家模型（MoDE, Di-BM, HiMoE 等）的技术细节，形成调研报告。完成所需背景知识储备，包括频域分析、MoE 路由机制、CALVIN 环境接口等。2026 年 1 月中旬确定总体模型设计方案，开始搭建基础代码框架（复现 FreqPolicy 主干部分）。
- **2026 年 2 月–3 月：**实现频域混合专家模块的代码。在模拟环境中调试 Freq-MoE-Policy 模型，确保 DCT 分解、专家输出融合、门控网络等功能正确。利用少量任务先行试运行，调整模型超参数（如频段划分、损失权重 α, β 等）。针对模型可能遇到的训练不稳定问题（例如专家竞争）进行对策研究，如增加熵正则保障门控的平稳训练等。2 月下旬初步完成模型的搭建和调优。
- **2026 年 4 月：**在 CALVIN 完整任务集上训练模型，并与 FreqPolicy 基线进行比较实验。记录各项评估指标，包括成功率、频谱特性、专家权重等数据。参加中期检查，将阶段性结果写入中期报告。根据中期反馈进一步完善实验设计，如增加对比实验或调整分析重点。
- **2026 年 5 月：**深入分析实验结果。完成不同任务下专家激活模式的可视化，总结 Freq-MoE-Policy 的优势与不足。撰写论文初稿的核心章节（方法、实验部分），并根据分析结果对模型作改进尝试（例如调整专家网络结构或训练策略）。如果有时间，可探索将本方法应用于真实机器人平台进行初步测试，验证其泛化能力。
- **2026 年 6 月：**整合全文，补充引言、相关工作、结论等内容，形成毕业论文完整稿。严格按照清华大学论文规范进行排版润色。同时，将论文送交导师审核，多轮修改以提高论文的科学性和表述清晰度。6 月中旬定稿并提交论文查重、盲审。准备答辩展示材料，包括幻灯片和演示视频等。根据评阅意见对论文做最后修改完善。6 月下旬参加论文答辩，汇报研究工作成果，回答答辩专家提问，力争顺利通过答辩，获得优秀成绩。

Notation

Symbol	Description
K	Number of experts in the MoE architecture
E_i	The i -th expert network, $i = 1, \dots, K$
h	Hidden action representation from backbone
π_i	Gating weight for expert i (dense softmax)
$\pi_i^{(k)}$	Sparse gating weight (Top- k routing)
$\mathcal{S}$	Set of activated experts in Top- k
$\mathbf{a}$	Time-domain action, $\mathbf{a} \in \mathbb{R}^{T \times d_a}$
$\mathbf{A}$	Frequency-domain action, $\mathbf{A} = \text{DCT}(\mathbf{a})$
$\mathbf{M}_i$	Frequency band mask for expert i
$\mathcal{B}_i$	Frequency subband of expert i
$v_t(x)$	Velocity field at time t in Flow Matching
$p_t(x)$	Probability distribution at time t
$\mathcal{L}_{\text{FM}}$	Flow Matching loss
$\mathcal{L}_{\text{cons}}$	Consistency loss (frequency + time domain)
$\mathcal{L}_{\text{balance}}$	Load balancing auxiliary loss
α_i	Weight for subband loss of expert i
β	Weight for overall action loss
γ	Weight for Flow Matching loss
η	Weight for consistency loss
ρ	Weight for sparsity regularization
T	Action sequence length (time steps)
d_a	Action space dimensionality

表 2: Mathematical notation used in this proposal.

参考文献

- [1] C. Chi, A. Borja, K. Pertsch, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. arXiv preprint, 2023.
- [2] Y. Lipman, R. Radhakrishnan, R. Jensen, et al. Flow Matching for Generative Modeling. In ICLR, 2023.
- [3] Q. Zhang, Z. Zhang, et al. FlowPolicy: Fast 3D Flow-based Policy via Consistency Flow Matching. In AAAI, 2025.
- [4] X. Liu, B. Song, et al. Rectified Flow: A Straight Flow Model for Generative Modeling. arXiv preprint, 2023.
- [5] H. Xue, et al. RecFlow Policy: One-step Visuomotor Policy with Rectified Flow Matching. arXiv preprint, 2025.

- [6] Y. Zhai, et al. Variational Flow-Matching Policy for Multi-Modal Robot Manipulation. arXiv preprint, 2025.
- [7] S. Braun, et al. Riemannian Flow Matching Policy for Robot Manipulation. arXiv preprint, 2025.
- [8] N. Shazeer, A. Mirhoseini, K. Maziarz, et al. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. In ICLR, 2017.
- [9] Learning Diverse Skills for Behavior Models with Mixture of Experts (Di-BM). ICLR submission, 2026.
- [10] MoLe-VLA: Layer-Mixture for Efficient Vision-Language-Action Models. arXiv preprint, 2025.
- [11] HiMoE-VLA: Hierarchical Mixture-of-Experts for Generalist Vision-Language-Action Policies. ICLR submission, 2026.
- [12] X. Zhong, et al. FreqPolicy: Frequency-Decomposed Visuomotor Policies for Hierarchical Control. arXiv preprint, 2025.
- [13] Y. Su, et al. FreqPolicy: Efficient Flow-based Visuomotor Policy via Frequency Consistency. In NeurIPS, 2025.